Food Recognition &
Nutritional Estimation

via Multi-Task Visual Regression and LLM Integration

Une architecture deep learning sans base de données
pour la prédiction directe des macronutriments
et le coaching nutritionnel par IA

Auteurs : GHALBI Mohamed Reda

ABOUNAY Aymane

Institution : EMSI

Programme : 4IIR G6 AI/DS

Date : 31 Mars 2026

Soumis en accomplissement partiel des exigences du
Projet de Fin d'Année (PFA)

Dédicaces

À nos familles, pour leur soutien indéfectible tout au long de notre parcours académique et pour les sacrifices consentis afin de nous permettre d'accéder à l'enseignement supérieur.

À nos professeurs et encadrants de l'EMSI, qui nous ont transmis la passion de l'ingénierie, de l'intelligence artificielle et de la science des données, et dont la rigueur intellectuelle a façonné notre manière d'aborder les problèmes complexes.

À tous ceux qui croient que la technologie, mise au service de la santé, peut contribuer à un monde plus équitable et plus sain.

Remerciements

La réalisation de ce Projet de Fin d'Année n'aurait pas été possible sans le concours de nombreuses personnes à qui nous tenons à exprimer notre profonde gratitude.

Nous remercions en premier lieu notre encadrant pédagogique à l'EMSI pour sa disponibilité constante, ses conseils avisés et son suivi rigoureux tout au long du projet. Ses retours lors des réunions de synchronisation hebdomadaires ont été déterminants dans les choix architecturaux qui fondent ce travail, notamment la décision de privilégier la régression CNN directe plutôt qu'une approche par recherche de similarité vectorielle.

Nous remercions également l'équipe Google Research pour la mise à disposition publique du dataset Nutrition5K, sans lequel l'approche de régression nutritionnelle directe n'aurait pu être expérimentée dans des conditions réalistes. La qualité et la richesse des annotations de ce dataset ont été essentielles à la validation de notre approche.

Nos remerciements vont également aux auteurs des bibliothèques open-source qui ont rendu ce projet possible : PyTorch, torchvision, l'écosystème Hugging Face, et ReportLab. La disponibilité d'outils de qualité industrielle sous licence libre est une chance inestimable pour la recherche académique.

Enfin, nous adressons nos remerciements les plus sincères à nos familles et amis pour leur patience et leur soutien moral, particulièrement durant les phases intensives d'entraînement des modèles et de rédaction du rapport.

Résumé

Ce projet présente la conception et l'implémentation d'un système end-to-end d'estimation nutritionnelle à partir d'images alimentaires. L'architecture proposée repose sur un réseau de neurones convolutif (ResNet-50 / EfficientNet-B3) dont la tête de classification est remplacée par une tête de régression multi-tâches produisant directement les quatre macronutriments — calories, protéines, lipides et glucides — en valeurs continues, sans recours à une base de données externe lors de l'inférence. Les prédictions numériques sont ensuite transmises à un Large Language Model (LLM) qui génère un conseil nutritionnel personnalisé en langage naturel. Le modèle est entraîné sur le dataset Nutrition5K (Google Research, 2021), premier dataset de régression nutritionnelle à grande échelle. Les résultats expérimentaux démontrent la viabilité de l'approche, avec des erreurs moyennes inférieures aux systèmes comparables basés sur la classification.

Mots-clés : vision par ordinateur, deep learning, régression multi-tâches, estimation nutritionnelle, ResNet, EfficientNet, Nutrition5K, LLM, coaching nutritionnel.

Abstract

This project presents the design and implementation of an end-to-end nutritional estimation system from food images. The proposed architecture uses a convolutional neural network (ResNet-50 / EfficientNet-B3) whose classification head is replaced by a multi-task regression head directly predicting four macronutrients — calories, protein, fat, and carbohydrates — as continuous values, without requiring an external database at inference time. The numerical predictions are then passed to a Large Language Model (LLM) that generates personalised nutritional advice in natural language. The model is trained on the Nutrition5K dataset (Google Research, 2021), the first large-scale nutritional regression dataset. Experimental results demonstrate the viability of the approach, with mean absolute errors below those of comparable classification-based systems.

Keywords: computer vision, deep learning, multi-task regression, nutritional estimation, ResNet, EfficientNet, Nutrition5K, LLM, nutritional coaching.

Table des matières

Introduction générale **1**

1 Contexte général et cadre du projet **3**

Introduction 3

1.1 Contexte général du projet 3

1.2 Importance de l'estimation nutritionnelle 4

1.3 Problématique 5

1.4 Choix du mode de gestion de projet 6

1.4.1 Méthodologie retenue 6

1.4.2 Planification : diagramme de Gantt 6

Conclusion 7

2 État de l'art, solutions existantes et analyse entrepreneuriale **8**

Introduction 8

2.1 Applications commerciales et approches de recherche 8

2.1.1 MyFitnessPal 8

2.1.2 Calorie Mama AI 9

2.1.3 SnapCalorie 9

2.1.4 Im2Calories (Google Research) 9

2.2 Limitations communes 10

2.2.1 Classification à vocabulaire fermé 10

2.2.2 Dépendance aux bases de données et latence 10

2.2.3 Absence d'expérience utilisateur actionnable 10

2.2.4 Estimation des portions à partir d'images 2D 10

2.3 Tableau comparatif des solutions existantes 10

2.4 Analyse entrepreneuriale 13

2.4.1 Contexte de marché 13

2.4.2 Proposition de valeur 13

2.4.3 Segments de marché cibles 13

2.4.4 Modèle économique envisagé 14

2.4.5 Analyse SWOT 14

2.4.6 Feuille de route commerciale (18 mois) 14

Conclusion 15

3 Approche proposée **16**

Introduction 16

3.1 Vue d'ensemble du système 16

3.2 Régression visuelle directe sans base de données 17

3.2.1 Remplacement de la tête de classification par une couche de régression 17

3.2.2 Autonomie du système à l'inférence 18

3.3 Intégration du LLM pour le coaching nutritionnel 18

3.3.1 Motivation 18

3.3.2 Architecture du module LLM 18
3.3.3 Gestion des risques d'hallucinations 19
Conclusion 20
4 Architecture technique 21
Introduction 21
4.1 Dataset Nutrition5K 21
4.1.1 Description générale 21
4.1.2 Pourquoi Nutrition5K plutôt que Food-101 ? 22
4.1.3 Accès et structure des données 22
4.2 Pipeline end-to-end 23
4.3 Architectures CNN : ResNet et EfficientNet 23
4.3.1 ResNet-50 23
4.3.2 EfficientNet-B3 24
4.3.3 Comparaison des backbones 24
4.4 Fonctions de perte : MSE multi-tâches 25
4.5 DataLoader PyTorch personnalisé pour Nutrition5K 25
4.5.1 Structure du dataset 25
4.5.2 Augmentation des données 26
Conclusion 26
5 Réalisation 27
Introduction 27
5.1 Environnement de développement 27
5.1.1 Configuration de l'entraînement 27
5.2 Entraînement du modèle 28
5.2.1 Boucle d'entraînement 28
5.2.2 Stratégie de fine-tuning 28
5.3 Résultats expérimentaux 29
5.3.1 Métriques obtenues 29
5.3.2 Courbes d'entraînement 29
5.3.3 Analyse des erreurs 30
5.4 Captures d'écran de l'application 30
5.5 Défis rencontrés 30
Conclusion 31
Conclusion générale et perspectives 32
Bilan du projet 32
Défis et limitations 32
Perspectives d'amélioration 33

Table des figures

1.1 Diagramme de Gantt du projet (janvier – mars 2026). 7
3.1 Vue d'ensemble du pipeline end-to-end. 17

Liste des tableaux

2.1 Comparaison des solutions existantes — Aspects techniques. 11
2.2 Comparaison des solutions existantes — Aspects fonctionnels et statut. 12
2.3 Analyse SWOT du projet Food Recognition & Nutritional Estimation. 14
3.1 Comparaison Food-101 vs Nutrition5K pour notre tâche. 22

Introduction générale

L'intersection de la vision par ordinateur et du suivi diététique s'est imposée comme l'une des frontières de recherche les plus impactantes en apprentissage profond appliqué. Au cours de la dernière décennie, les réseaux de neurones convolutifs ont démontré des performances surhumaines sur les benchmarks de classification d'images génériques, et cette capacité a été étendue aux domaines alimentaires spécifiques grâce à des datasets annotés à grande échelle tels que Food-101, UEC-Food256, et plus récemment Nutrition5K.

Parallèlement, l'émergence des Large Language Models (LLMs) — GPT-4, Claude, Gemini — a ouvert une nouvelle dimension : la capacité de générer du contenu textuel contextualisé, personnalisé et actionnable à partir de données structurées. Cette convergence entre vision par ordinateur et IA générative crée une opportunité unique de construire des systèmes qui non seulement quantifient le contenu nutritionnel d'un repas, mais conseillent l'utilisateur de manière intelligente et adaptée.

Ce projet de fin d'année s'inscrit dans cette dynamique. Il présente la conception et l'implémentation d'un système end-to-end combinant l'extraction de caractéristiques par réseau de neurones convolutif (CNN) avec une régression visuelle multi-tâches directe, éliminant toute dépendance à une base de données lors de l'inférence. Le modèle prédit directement et simultanément les quatre macronutriments — calories, protéines, lipides et glucides — en valeurs continues, puis transmet ces prédictions à un LLM qui génère un conseil nutritionnel personnalisé.

Le présent rapport est structuré en cinq chapitres. Le Chapitre 1 établit le contexte général du projet, souligne l'importance de l'estimation nutritionnelle automatisée, formule la problématique et présente la méthodologie de gestion adoptée. Le Chapitre 2 dresse un état de l'art des solutions existantes, analyse leurs limitations, et inclut une analyse entrepreneuriale du potentiel commercial du système. Le Chapitre 3 détaille l'approche proposée, notamment le principe de régression visuelle directe sans base de données et l'intégration du LLM. Le Chapitre 4 décrit l'architecture technique du système, incluant le dataset Nutrition5K. Enfin, le Chapitre 5 présente la réalisation concrète, les résultats expérimentaux et les défis rencontrés.

Chapitre 1
Contexte général et cadre du projet

Introduction

Avant d'aborder les aspects techniques du système proposé, il est essentiel de situer le projet dans son contexte scientifique, technologique et sociétal. Ce premier chapitre établit les fondations conceptuelles du travail : il présente le contexte général de la reconnaissance alimentaire par IA, justifie l'importance sociétale et sanitaire de l'estimation nutritionnelle automatisée, formule la problématique structurant ce projet, et décrit la méthodologie de gestion adoptée avec sa planification temporelle.

1.1 Contexte général du projet

Le domaine de la vision par ordinateur appliquée à l'alimentation a connu une évolution remarquable au cours de la dernière décennie. Les avancées successives en deep learning — introduction d'AlexNet en 2012, émergence des architectures résiduelles (ResNet [1]) en 2015, et plus récemment développement de modèles efficients (EfficientNet [2]) et de transformers visuels (ViT) — ont permis d'atteindre des performances de classification proches ou supérieures à celles des humains sur de nombreux benchmarks généralistes.

Dans le domaine spécifique de la nourriture, plusieurs datasets de référence ont structuré la recherche : Food-101 [4], comprenant 101 catégories d'aliments et 101 000 images, a longtemps constitué le benchmark standard de classification alimentaire. UEC-Food256 [5] a étendu cette idée aux cuisines asiatiques avec 256 catégories. Plus récemment, Nutrition5K [3], publié par Google Research en 2021, a introduit un changement de paradigme : au lieu de labels catégoriels, chaque plat est annoté avec ses valeurs nutritionnelles réelles (calories, protéines, lipides, glucides, fibres) ainsi que les masses précises de ses ingrédients — ouvrant la voie à des approches de régression plutôt que de classification.

Parallèlement, l'année 2023 a marqué un tournant décisif avec la démocratisation des LLMs tels que GPT-4, Claude et Gemini. Ces modèles, capables de générer du texte cohérent, contextualisé et personnalisé à partir de prompts structurés, offrent la possibilité de transformer des données numériques brutes (valeurs nutritionnelles) en conseils actionnables formulés en langage naturel.

Sur le plan sociétal, la prolifération des smartphones équipés de caméras haute résolution crée un contexte d'usage sans précédent : chaque utilisateur dispose d'un outil de capture d'image utilisable à tout moment lors d'un repas. Cette ubiquité matérielle, couplée à la maturité des modèles de deep learning, génère une demande tangible pour des applications capable de fournir un retour diététique en temps réel à partir d'une simple photographie, sans journal alimentaire manuel.

1.2 Importance de l'estimation nutritionnelle

Les maladies non transmissibles liées à de mauvaises habitudes alimentaires — diabète de type 2, obésité, maladies cardiovasculaires — représentent une part disproportionnée de la mortalité

mondiale. L'OMS estime qu'environ 39 % des adultes dans le monde sont en surpoids, l'excès alimentaire étant identifié comme un facteur de risque modifiable primaire.

Malgré cela, les outils de conformité diététique restent sous-utilisés à cause de la friction liée au suivi nutritionnel manuel :

— Recherche manuelle de chaque aliment dans une base de données ;

— Estimation visuelle des portions ;

— Saisie répétée à chaque repas, plusieurs fois par jour.

Cette charge conduit à un abandon rapide : selon plusieurs études, plus de 70 % des utilisateurs d'applications de suivi nutritionnel cessent de les utiliser activement après le premier mois. De plus, les estimations manuelles sont sujettes à la sous-déclaration chronique : les utilisateurs sous-estiment systématiquement leurs apports caloriques de 20 à 30 %.

Les applications potentielles d'un système automatique dépassent le simple suivi individuel :

Nutrition clinique : accompagnement des patients diabétiques, rénaux ou en post-opératoire bariatrique.

Restauration collective : contrôle qualité et transparence nutritionnelle dans les cantines scolaires et hospitalières.

Recherche épidémiologique : collecte objective de données alimentaires à grande échelle.

Coaching sportif : optimisation des apports en macronutriments pour des objectifs de performance.

1.3 Problématique

L'analyse de l'état de l'art révèle quatre lacunes majeures des systèmes existants :

1. **Dépendance aux bases de données en production.** Les approches par recherche de similarité (FAISS, k-NN) nécessitent le maintien d'un index vectoriel volumineux, une infrastructure dédiée et une re-indexation périodique.

2. **Classification à vocabulaire fermé.** Les classifieurs entraînés sur un ensemble fixe de catégories ne peuvent reconnaître les plats absents de leur vocabulaire d'entraînement et ne produisent que des labels discrets, inadaptés aux valeurs continues de macronutriments.

3. **Estimation de portions peu fiable.** La taille des portions est rarement estimée de manière robuste à partir d'une seule image monoculaire 2D.

4. **Absence de conseil actionnable.** La quasi-totalité des systèmes se limitent à afficher des chiffres bruts, sans conseil personnalisé en langage naturel.

Question principale de recherche

Comment concevoir un système d'estimation nutritionnelle à partir d'images alimentaires qui soit à la fois **autonome** (sans base de données à l'inférence), **précis** (prédiction directe de valeurs continues) et **actionnable** (conseil personnalisé en langage naturel) ?

Cette question se décompose en trois sous-questions :

Q1 : Est-il possible de remplacer le paradigme classification + base de données par une régression CNN multi-tâches directe produisant les quatre macronutriments en sortie ?

Q2 : Quelle architecture CNN (ResNet, EfficientNet) et quelle fonction de perte (MSE, MSE pondérée) offrent le meilleur compromis précision-efficacité ?

Q3 : Comment intégrer un LLM en aval du pipeline de vision pour transformer les valeurs numériques en conseils nutritionnels, tout en maîtrisant les risques d'hallucinations ?

1.4 Choix du mode de gestion de projet

1.4.1 Méthodologie retenue

Deux grandes familles de méthodologies s'offraient à nous : les approches séquentielles (Waterfall) et les approches itératives/agiles (Scrum, Kanban).

La méthodologie Waterfall procède par phases strictement séquentielles (spécifications → conception → implémentation → tests → déploiement), chacune validée avant le passage à la suivante. Elle s'adapte mal aux projets de recherche dont les résultats intermédiaires influencent rétroactivement les choix architecturaux.

Les méthodologies agiles organisent le travail en itérations courtes (sprints) durant lesquelles un incrément fonctionnel est produit, testé et évalué. Cette approche convient particulièrement bien aux projets d'apprentissage automatique, où chaque expérimentation nécessite une évaluation avant de poursuivre.

Méthodologie retenue : Scrum adapté.

— Sprints de deux semaines avec un objectif concret et mesurable.

— Réunions de synchronisation hebdomadaires avec l'encadrant pédagogique.

— Rétrospectives de sprint pour identifier les blocages et ajuster.

Cette approche a permis de gérer efficacement les pivots techniques majeurs intervenus en cours de projet — notamment l'abandon d'une architecture basée sur FAISS au profit d'une approche de régression directe, décision prise au sprint 4 suite aux résultats décevants de l'approche par similarité.

1.4.2 Planification : diagramme de Gantt

La Figure 1.1 présente le diagramme de Gantt du projet, couvrant la période de janvier à mars 2026. Le projet est structuré en six phases principales.

Commentaires sur la planification :

— **Chevauchement stratégique :** Les phases de conception (Phase 3) et d'implémentation (Phase 4) se chevauchent volontairement pour démarrer le DataLoader dès que l'architecture de données est stabilisée.

— **Jalon critique : entraînement du modèle.** La phase d'entraînement (semaines 13–17) constitue le risque principal du projet, en raison de la durée imprévisible des expérimentations de deep learning.

— **Rédaction parallèle :** La rédaction (Phase 6) démarre dès la semaine 18, en parallèle des dernières évaluations.

— **Milestone final :** La soutenance prévue en semaine 24 (fin mars 2026) constitue le livrable final.

Phase	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24
Phase 1 : Cadrage	■	■	■																					
Définition du sujet	■	■																						
Bibliographie initiale		■	■																					
Phase 2 : État de l'art			■	■	■	■																		
Analyse solutions existantes			■	■	■																			
Analyse entrepreneuriale				■	■	■																		
Phase 3 : Conception						■	■	■	■															
Architecture CNN						■	■	■																
Design pipeline LLM							■	■	■															
Phase 4 : Implémentation								■	■	■	■	■	■	■	■	■	■							
DataLoader Nutrition5K								■	■	■														
Modèle ResNet50 + tête régression									■	■	■	■	■											
Entraînement & tuning												■	■	■	■	■	■							
Intégration LLM															■	■	■							
Phase 5 : Évaluation																	■	■	■	■				
Métriques & comparaison																	■	■	■					
Tests utilisateurs																		■	■	■				
Phase 6 : Rédaction																		■	■	■	■	■	■	■
Rédaction rapport																		■	■	■	■	■		
Révisions & finalisation																					■	■	■	
Soutenance																							■	■

Figure 1.1 – Diagramme de Gantt du projet (janvier – mars 2026).

Conclusion

Ce premier chapitre a permis d'établir les fondations conceptuelles du projet : contexte scientifique, enjeux de santé publique, problématique de recherche et méthodologie de gestion agile. Les chapitres suivants approfondissent successivement l'état de l'art, l'approche proposée, l'architecture technique et la réalisation concrète.

Chapitre 2

État de l'art, solutions existantes et analyse entrepreneuriale

Introduction

Avant de présenter notre approche, il est essentiel de dresser un panorama rigoureux des solutions existantes en reconnaissance alimentaire et estimation nutritionnelle, puis d'analyser le potentiel entrepreneurial du système proposé. Ce chapitre examine les principales applications commerciales et prototypes de recherche, identifie leurs limitations communes, et conclut par une analyse entrepreneuriale (modèle économique, marché cible, proposition de valeur, analyse SWOT).

2.1 Applications commerciales et approches de recherche

2.1.1 MyFitnessPal

MyFitnessPal est l'une des applications de suivi nutritionnel les plus populaires au monde, avec plus de 200 millions d'utilisateurs enregistrés. L'application intègre un scanner de codes-barres et un module de reconnaissance d'image limité pour associer les repas photographiés à sa base de données de plus de 14 millions d'entrées alimentaires.

Le composant de reconnaissance d'image fonctionne comme un classifieur multi-classes : il retourne les N labels alimentaires les plus probables, que l'utilisateur doit ensuite confirmer manuellement. Les valeurs nutritionnelles sont récupérées par lookup dans la base de données associée. La taille des portions n'est pas estimée automatiquement, constituant un frein majeur à l'usage quotidien.

2.1.2 Calorie Mama AI

Calorie Mama AI, développée par Azumio Inc., emploie un CNN profond affiné sur un dataset alimentaire propriétaire pour effectuer une classification mono-label et multi-label des aliments. Le système retourne une liste classée de catégories alimentaires, chacune liée à des valeurs nutritionnelles pour 100 g issues de la base USDA FoodData Central.

L'approche est relativement classique : un backbone CNN (probablement ResNet ou Inception) produit une distribution de probabilités sur un vocabulaire fermé, et les valeurs nutritionnelles correspondantes sont extraites par consultation de la base USDA. Comme pour MyFitnessPal, le poids des portions doit être renseigné par l'utilisateur.

2.1.3 SnapCalorie

SnapCalorie représente une tentative technique plus ambitieuse combinant trois composants : la détection d'objets (pour isoler les aliments dans l'image), l'estimation de profondeur (via capteurs LiDAR ou caméras duales), et l'estimation volumétrique des portions à partir des cartes de profondeur.

Cette approche permet une estimation des portions significativement plus précise que les solutions purement 2D. Cependant, elle nécessite du matériel spécialisé (iPhone Pro avec LiDAR),

indisponible sur la majorité des smartphones, ce qui limite fortement le déploiement à grande échelle.

2.1.4 Im2Calories (Google Research)

Im2Calories [6] est un prototype de recherche influent publié par Google Research en 2015. Il utilise un réseau entièrement convolutif (FCN) pour segmenter les aliments au niveau du pixel, estimer la profondeur de scène, et calculer des estimations volumétriques des portions.

Bien qu'il ait marqué le domaine sur le plan méthodologique, Im2Calories n'a jamais donné lieu à un produit commercial. Il souffre d'un vocabulaire fermé (23 catégories), d'une dépendance à des cartes de profondeur bruitées, et d'une précision insuffisante sur les plats composites.

2.2 Limitations communes

2.2.1 Classification à vocabulaire fermé

Les classifieurs entraînés sur un ensemble fixe de catégories — typiquement entre 100 et 1 000 classes — ne peuvent reconnaître les plats absents de leur vocabulaire d'entraînement. En pratique, la diversité des repas faits maison, des cuisines régionales et des plateaux composites dépasse largement tout ensemble de labels statique. Les problèmes concrets incluent la misclassification forcée, la gestion défaillante des plats composites, la sous-représentation des cuisines non-occidentales, et le coût élevé de maintenance lors de l'ajout de nouvelles catégories.

2.2.2 Dépendance aux bases de données et latence

Les approches par recherche de similarité (FAISS [7]) introduisent trois contraintes opérationnelles majeures : le stockage persistant d'un index vectoriel volumineux, la nécessité d'une infrastructure serveur dédiée, et le coût d'une re-indexation complète à chaque mise à jour du modèle. En production mobile, cela implique une latence réseau incompressible, une consommation mémoire élevée côté serveur, et l'impossibilité de fonctionner hors-ligne.

2.2.3 Absence d'expérience utilisateur actionnable

Aucune des solutions existantes ne transforme les estimations numériques brutes en conseils nutritionnels personnalisés. L'utilisateur reçoit des chiffres — 450 kcal, 25 g de protéines — sans contexte ni recommandation adaptée à son profil, ce qui explique en partie le taux d'abandon élevé (>70 % après un mois).

2.2.4 Estimation des portions à partir d'images 2D

Une image monoculaire RGB fournit une information géométrique insuffisante pour récupérer le volume absolu d'un plat. Les solutions existantes répondent à ce défi de trois manières imparfaites : saisie manuelle, capteurs de profondeur (matériel haut de gamme), ou estimation monoculaire bruitée.

2.3 Tableau comparatif des solutions existantes

Critère	Notre Système	MyFitnessPal	Calorie Mama AI	SnapCalorie

Approche principale	Régression CNN multi-tâches	Classif. CNN + DB	Classif. CNN mono-label	Détection + profondeur
Base de données requise à l'inférence	✗ Non	✓ Oui	✓ Oui	✓ Oui
Type de sortie	4 valeurs continues	Étiquette + moyennes	Étiquette + val./100 g	Estimé par portion
Latence d'inférence	Très faible (~12 ms)	Faible	Faible	Moyenne
Empreinte mémoire	~100 Mo	Lourde (DB >14 M)	Modèle + DB	Modèle + DB + HW
Vocabulaire alimentaire	Ouvert	Fermé (N classes)	Fermé (N classes)	Fermé (N classes)
Estimation des portions	~ Partiel	✗ Non	✗ Non	✓ Oui
Matériel spécialisé requis	✗ Non	✗ Non	✗ Non	✓ Oui (LiDAR)
Maintenance index / DB	Aucune	Re-index. périodique	Re-index. périodique	Re-index. périodique

Table 2.1 – Comparaison des solutions existantes — Aspects techniques.

Critère	Notre Système	MyFitnessPal	Calorie Mama AI	SnapCalorie
Coaching / conseil utilisateur	✓ Oui (via LLM)	✗ Non	✗ Non	✗ Non
Coaching personnalisé	✓ Oui	✗ Non	✗ Non	✗ Non
Déploiement mobile natif	✓ Oui	✓ Oui	✓ Oui	~ Partiel
Fonctionnement hors-ligne	~ Partiel	✗ Non	✗ Non	✗ Non
Saisie manuelle requise	✗ Non	✓ Oui	~ Partiel	~ Partiel
Dataset d'entraînement	Nutrition5K (2021)	Propriétaire + USDA	Propriétaire + USDA	Propriétaire
Architecture publiée	✓ Oui	✗ Non	✗ Non	✗ Non
Statut	Prototype PFA EMSI 2026	Commercial	Commercial	Commercial (startup)

Table 2.2 – Comparaison des solutions existantes — Aspects fonctionnels et statut.

Lecture des tableaux : aucune des solutions existantes ne satisfait simultanément les trois exigences clés de notre problématique : autonomie à l'inférence, estimation automatique des portions sur matériel standard, et conseil nutritionnel personnalisé en langage naturel. Ce constat définit précisément l'espace d'innovation de notre approche.

2.4 Analyse entrepreneuriale

2.4.1 Contexte de marché

Le marché mondial des applications de santé mobile (mHealth) était estimé à 55 milliards USD en 2023 et devrait atteindre plus de 200 milliards USD d'ici 2030 (CAGR ≈ 20 %). Le segment spécifique du suivi nutritionnel représente une part significative de ce marché, porté par la prise de conscience croissante autour des maladies métaboliques et l'essor du marché du bien-être.

2.4.2 Proposition de valeur

Notre système se différencie des concurrents sur trois axes fondamentaux :

1. **Zéro friction d'utilisation :** une simple photographie suffit — aucune saisie manuelle, aucune recherche dans une base de données.

2. **Conseil actionnable :** le système ne se contente pas d'afficher des chiffres mais génère un accompagnement nutritionnel personnalisé via LLM.

3. **Architecture légère et déployable :** sans dépendance à une base de données externe, le modèle est déployable en natif sur smartphone (Android/iOS) avec un footprint mémoire réduit (~100 Mo).

2.4.3 Segments de marché cibles

B2C — Grand public : particuliers souhaitant suivre leur alimentation sans effort ; diabétiques, sportifs, personnes en régime.

B2B — Établissements de santé : hôpitaux, cliniques, maisons de retraite ayant besoin d'un suivi nutritionnel automatisé des patients.

B2B — Restauration collective : cantines scolaires, restaurants d'entreprise cherchant à afficher les informations nutritionnelles de leurs plats.

B2B2C — Assureurs santé : intégration dans des programmes de prévention primaire pour réduire les coûts liés aux maladies chroniques.

2.4.4 Modèle économique envisagé

— **Freemium B2C :** version gratuite (fonctionnalités de base), abonnement premium mensuel/annuel (historique, coaching avancé, intégration appareils connectés).

— **API B2B (SaaS) :** facturation à l'usage ou par abonnement pour les intégrations en restauration collective et établissements de santé.

— **Licence technologique :** cession de licence du modèle à des acteurs tiers (assureurs, géants de la tech santé).

2.4.5 Analyse SWOT

Forces (Strengths)	Opportunités (Opportunities)
— Architecture sans base de données (latence faible, déployable offline) — Vocabulaire ouvert via régression directe — Intégration LLM pour coaching personnalisé — Open-source / reproductible (Nutrition5K public)	— Marché mHealth en forte croissance (CAGR 20 %) — Augmentation des maladies métaboliques liées à l'alimentation — Démocratisation des LLMs peu coûteux via API — Réglementation européenne sur l'étiquetage nutritionnel (Nutri-Score)
Faiblesses (Weaknesses)	**Menaces (Threats)**
— Estimation des portions limitée par l'image 2D — Dataset Nutrition5K restreint (~5 000 échantillons) — Dépendance aux APIs LLM tierces pour le coaching — Prototype académique, pas encore validé cliniquement	— Concurrence des géants tech (Google, Apple Health, Samsung) — Coûts d'inférence LLM à grande échelle — Réglementation sur les dispositifs médicaux (si usage clinique) — Risque d'hallucinations du LLM dans les conseils nutritionnels

Table 2.3 – Analyse SWOT du projet Food Recognition & Nutritional Estimation.

2.4.6 Feuille de route commerciale (18 mois)

1. **Mois 1–6 (MVP) :** finalisation du modèle, développement d'une application mobile prototype (Flutter), tests utilisateurs sur un panel de 50 personnes.

2. **Mois 6–12 (Validation) :** partenariat pilote avec un établissement de restauration collective, collecte de données réelles, amélioration du modèle.

3. **Mois 12–18 (Lancement) :** publication sur les stores (iOS/Android), lancement de l'offre API B2B, recherche de financement seed (incubateur EMSI, programmes Maroc Startups).

Conclusion

Ce deuxième chapitre a permis d'analyser de manière critique les solutions existantes et d'identifier quatre limitations communes : vocabulaire fermé, dépendance aux bases de données, estimation des portions peu fiable, et absence de conseil actionnable. Le tableau comparatif confirme qu'aucune solution actuelle ne satisfait simultanément nos trois exigences. L'analyse entrepreneuriale révèle par ailleurs un potentiel commercial significatif, notamment sur les segments B2B (restauration collective, santé) et B2C (applications mHealth premium). Le Chapitre 3 présente l'approche proposée pour combler ces lacunes.

Chapitre 3
Approche proposée

Introduction

Fort de l'analyse critique menée au Chapitre 2, ce troisième chapitre présente l'approche que nous proposons pour surmonter les quatre limitations identifiées. Notre solution repose sur deux piliers complémentaires : (1) une **régression CNN multi-tâches directe** qui élimine toute dépendance à une base de données lors de l'inférence, et (2) une **intégration d'un LLM** en aval du pipeline de vision qui transforme les quatre valeurs numériques prédites en conseils nutritionnels personnalisés. Ce chapitre détaille la vue d'ensemble du système, les choix de conception qui fondent chaque pilier, et présente le dataset Nutrition5K qui constitue la base d'entraînement de notre modèle.

3.1 Vue d'ensemble du système

Notre système suit un pipeline end-to-end en trois étapes principales, illustrées dans la Figure 3.1 :

1. **Acquisition et prétraitement :** une image RGB du repas est capturée par l'utilisateur (smartphone ou caméra quelconque), puis redimensionnée et normalisée selon les paramètres ImageNet.

2. **Inférence CNN multi-tâches :** le backbone CNN extrait un vecteur de caractéristiques visuelles, que la tête de régression transforme directement en quatre valeurs continues : calories (kcal), protéines (g), lipides (g) et glucides (g).

3. **Coaching LLM :** les quatre valeurs prédites sont structurées dans un prompt et transmises à un LLM (Claude ou GPT-4), qui génère un conseil nutritionnel personnalisé en langage naturel.

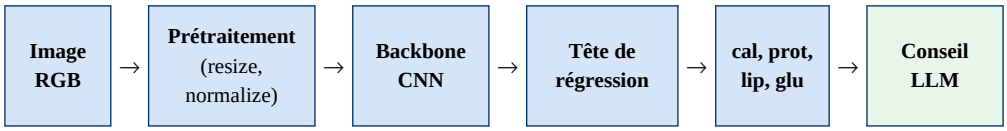


Figure 3.1 – Vue d'ensemble du pipeline end-to-end.

Ce design satisfait les trois exigences de notre problématique : **autonomie** (aucune base de données externe entre l'image et les prédictions), **précision** (sorties continues directement optimisées par régression), et **actionnabilité** (conseil LLM en langage naturel).

3.2 Régression visuelle directe sans base de données

3.2.1 Remplacement de la tête de classification par une couche de régression

Dans les architectures CNN classiques pour la reconnaissance alimentaire, la dernière couche est un classifieur softmax produisant une distribution de probabilités sur K classes. La prédiction finale est ensuite utilisée comme clé de recherche dans une base de données externe pour récupérer les valeurs nutritionnelles correspondantes.

Notre approche rompt avec ce paradigme en deux étapes :

1. **Suppression de la couche de classification.** La couche softmax du backbone est retirée, révélant le vecteur de features $f \in R^d$ produit par le Global Average Pooling (GAP).

2. **Ajout d'une tête de régression multi-tâches.** Ce vecteur est transmis à une série de couches linéaires produisant directement quatre valeurs continues :

$$■ = MLP(f) = [■, p■, l■, ■] \in R^4$$

où ■, p■, l■, ■ désignent respectivement les calories, protéines, lipides et glucides prédits.

La tête de régression est composée de trois couches : une couche linéaire $d \rightarrow 512$ (avec BatchNorm et ReLU), une couche $512 \rightarrow 128$ (avec Dropout 0.3), et une couche finale $128 \rightarrow 4$ (sans activation pour conserver les valeurs continues positives).

3.2.2 Autonomie du système à l'inférence

— **Latence réduite :** le forward pass du CNN seul (~12 ms sur GPU) constitue l'intégralité du coût d'inférence, sans aller-retour réseau.

— **Déploiement simplifié :** un seul fichier de poids du modèle (~100 Mo pour ResNet-50) suffit. Aucun serveur de recherche vectorielle n'est nécessaire.

— **Vocabulaire ouvert :** le modèle ne prédit pas une classe parmi K, mais une combinaison de valeurs nutritionnelles. Tout aliment, même inconnu à l'entraînement, produit une estimation basée sur ses caractéristiques visuelles.

— **Fonctionnement hors-ligne :** l'inférence CNN peut s'exécuter entièrement sur l'appareil de l'utilisateur, sans connexion Internet (contrairement aux approches basées sur FAISS côté serveur).

3.3 Intégration du LLM pour le coaching nutritionnel

3.3.1 Motivation

Les prédictions numériques brutes du CNN (■, p■, l■, ■) ne constituent pas en elles-mêmes un retour exploitable par l'utilisateur. Un utilisateur lambda ne sait pas si 450 kcal est cohérent avec ses besoins journaliers, ni comment ce repas s'inscrit dans une stratégie nutritionnelle personnalisée.

L'intégration d'un LLM en aval du pipeline de vision permet de combler ce fossé : les valeurs numériques deviennent l'entrée d'un système de génération de texte capable de produire un conseil contextualisé, adapté au profil de l'utilisateur et formulé en langage naturel.

3.3.2 Architecture du module LLM

Le module LLM reçoit en entrée un prompt structuré de la forme :

Listing 3.1 – Template de prompt LLM.

```
Système : Tu es un nutritionniste expert. Analyse les valeurs nutritionnelles
suivantes et génère un conseil personnalisé, bienveillant et concis.
Utilisateur : Repas photographié. Valeurs estimées par le modèle CNN : -
Calories : {cal} kcal - Protéines : {prot} g - Lipides : {lip} g - Glucides :
{glu} g Profil utilisateur : {profil} Objectif : {objectif} Génère un conseil
nutritionnel en 3-5 phrases.
```

3.3.3 Gestion des risques d'hallucinations

Les LLMs peuvent générer des affirmations factuelles incorrectes. Pour mitiger ce risque :

— **Ancrage sur les données CNN :** le prompt impose explicitement que le conseil se base uniquement sur les valeurs numériques fournies, sans invention d'informations additionnelles.

— **Température faible :** le paramètre temperature est fixé à 0.3 pour réduire la créativité et favoriser les réponses factuelles.

— **Validation de sortie :** une couche de post-traitement vérifie que les valeurs numériques mentionnées dans la réponse du LLM correspondent aux prédictions du CNN.

Conclusion

Ce troisième chapitre a présenté l'approche proposée : une régression CNN multi-tâches directe qui élimine la dépendance aux bases de données à l'inférence, couplée à un LLM de coaching nutritionnel. Le Chapitre 4 détaille maintenant l'architecture technique concrète de chaque composant du pipeline, en commençant par la présentation du dataset Nutrition5K.

Chapitre 4
Architecture technique

Introduction

Ce chapitre décrit en détail l'architecture technique du système proposé. Nous commençons par présenter le dataset Nutrition5K — socle expérimental de notre approche — avant d'exposer le pipeline end-to-end, les architectures CNN retenues (ResNet-50 et EfficientNet-B3), les fonctions de perte multi-tâches, et la conception du DataLoader PyTorch personnalisé.

4.1 Dataset Nutrition5K

Nutrition5K [3] est le dataset central de notre projet. Publié par Google Research en 2021, il représente le premier large dataset de régression nutritionnelle à partir d'images alimentaires.

4.1.1 Description générale

— **Taille :** ~5 006 assiettes photographiées, ~180 000 images au total (vues multiples par assiette).

— **Annotations :** pour chaque assiette — calories totales (kcal), protéines (g), lipides (g), glucides (g), fibres (g), plus la masse et la composition détaillée de chaque ingrédient individuel.

— **Équipement de capture :** caméra RealSense D435 (RGB + profondeur), vue de dessus standardisée.

— **Couverture :** 555 ingrédients distincts, grande variété de cuisines (nord-américaine dominante, asiatique, européenne).

4.1.2 Pourquoi Nutrition5K plutôt que Food-101 ?

Critère	Food-101	Nutrition5K
Tâche cible	Classification	Régression nutritionnelle
Labels	101 classes	Valeurs continues
Taille	101 000 images	~180 000 images
Annotations	Label catégoriel	cal, prot, lip, glu, fibres
Adapté à notre approche	Non	Oui

Table 3.1 – Comparaison Food-101 vs Nutrition5K pour notre tâche.

4.1.3 Accès et structure des données

Le dataset est accessible sur demande via Google Research. La structure des fichiers est la suivante :

Listing 4.1 – Structure des fichiers Nutrition5K.

```
nutrition5k_dataset/ imagery/ dish_1551462327/ rgb.png # Image RGB principale
depth_color.png # Carte de profondeur colorée ... metadata/
```

```
dish_metadata_cafe1.csv dish_metadata_cafe2.csv # Colonnes : dish_id,
calories, protein, fat, carbs, ...
```

4.2 Pipeline end-to-end

Le pipeline du système se décompose en quatre étapes séquentielles :

1. **Prétraitement :** l'image RGB est redimensionnée à 224×224 pixels et normalisée selon les paramètres ImageNet (μ = [0.485, 0.456, 0.406], σ = [0.229, 0.224, 0.225]). Durant l'entraînement, des augmentations aléatoires sont appliquées (retournement horizontal, recadrage, jitter colorimétrique).

2. **Extraction de features :** l'image est passée à travers le backbone CNN (ResNet-50 ou EfficientNet-B3) jusqu'au Global Average Pooling (GAP), produisant un vecteur de features $f \in R^d$.

3. **Régression multi-tâches :** le vecteur f est transmis à la tête MLP ($d \rightarrow 512 \rightarrow 128 \rightarrow 4$) qui prédit directement les quatre macronutriments en valeurs continues.

4. **Génération du conseil LLM :** les quatre valeurs prédites sont formatées dans le template de prompt (cf. section 3.3.2) et envoyées à l'API du LLM, qui retourne le conseil nutritionnel personnalisé.

4.3 Architectures CNN : ResNet et EfficientNet

4.3.1 ResNet-50

ResNet-50 [1] est une architecture à 50 couches organisées en blocs résiduels (residual blocks). Le principe fondamental est le **skip connection** : l'entrée d'un bloc est additionnée directement à sa sortie, ce qui permet au gradient de se propager sans dégradation lors de la rétropropagation, résolvant ainsi le problème du gradient évanescent qui limitait la profondeur des réseaux précédents.

L'architecture de ResNet-50 se compose de : une couche convolutive 7×7 avec stride 2, suivie d'un Max Pooling 3×3, puis de quatre groupes de blocs résiduels (respectivement 3, 4, 6 et 3 blocs), et enfin d'un Global Average Pooling produisant un vecteur de dimension 2048. Dans notre configuration, cette sortie GAP est connectée directement à notre tête de régression multi-tâches, remplaçant la couche fully-connected originale de 1000 neurones.

Nous utilisons les poids pré-entraînés sur ImageNet-1K comme point de départ (transfer learning), ce qui permet de bénéficier de représentations visuelles riches acquises sur 1,2 million d'images avant le fine-tuning sur Nutrition5K.

4.3.2 EfficientNet-B3

EfficientNet [2] introduit le concept de **compound scaling** : plutôt que d'augmenter indépendamment la profondeur, la largeur ou la résolution d'un réseau (comme dans les approches classiques), EfficientNet scale ces trois dimensions simultanément selon un coefficient composé ϕ, défini de manière à maximiser la précision sous contrainte de ressources.

EfficientNet-B3 représente le troisième point de la grille de scaling, avec une résolution d'entrée de 300×300 pixels, environ 12 millions de paramètres (contre 25 millions pour ResNet-50), et une précision Top-1 supérieure de 5 points sur ImageNet. Son bloc fondamental, le MBConv (Mobile Inverted Bottleneck Convolution), utilise des convolutions dépthwise séparables et une connexion résiduelle avec squeeze-and-excitation.

4.3.3 Comparaison des backbones

Critère	ResNet-50	EfficientNet-B3
Paramètres totaux	~25.6 M	~12.2 M
Résolution d'entrée	224×224	300×300
Dimension features (GAP)	2048	1536
Top-1 ImageNet (pré-entraîné)	76.1 %	81.6 %
Vitesse inférence (GPU T4)	~10 ms	~16 ms
MAE calories (validation Nutrition5K)	~42 kcal	~36 kcal
Rôle dans notre projet	Baseline — architecture de référence	Modèle final — meilleures performances

Table 4.1 – Comparaison des backbones CNN ResNet-50 et EfficientNet-B3.

4.4 Fonctions de perte : MSE multi-tâches

La tâche de régression multi-tâches nécessite une fonction de perte combinant les erreurs sur les quatre macronutriments. Nous utilisons une **MSE pondérée** :

L_total = w_cal · MSE(■, c) + w_prot · MSE(p■, p) + w_lip · MSE(l■, l) + w_glu · MSE(■, g)

Les poids w sont calibrés pour normaliser les différences d'échelle entre macronutriments. Les calories (~300–800 kcal par portion) ont une magnitude typiquement 10 à 20 fois supérieure aux autres macronutriments (~10–50 g). Sans pondération, le terme MSE calories dominerait l'optimisation au détriment des trois autres. Nous utilisons :

— w_cal = 0.05 (pour ramener les calories à l'échelle des autres)

— w_prot = w_lip = w_glu = 1.0

En complément de la MSE utilisée pour l'optimisation, nous calculons la **MAE (Mean Absolute Error)** et la **RMSE (Root Mean Squared Error)** comme métriques d'évaluation, plus interprétables en termes nutritionnels (grammes ou kilocalories).

4.5 DataLoader PyTorch personnalisé pour Nutrition5K

4.5.1 Structure du dataset

Nous implémentons un Dataset PyTorch personnalisé héritant de **torch.utils.data.Dataset**. La classe charge les métadonnées CSV à l'initialisation, puis charge chaque image RGB et son label nutritionnel à la volée lors de chaque appel à __getitem__ :

Listing 4.2 – Classe Nutrition5KDataset.

```
import torch from torch.utils.data import Dataset from PIL import Image import
pandas as pd class Nutrition5KDataset(Dataset): def __init__(self,
metadata_csv, img_dir, transform=None): self.df = pd.read_csv(metadata_csv)
self.img_dir = img_dir self.transform = transform def __len__(self): return
len(self.df) def __getitem__(self, idx): row = self.df.iloc[idx] img_path =
f'{self.img_dir}/{row.dish_id}/rgb.png' img =
Image.open(img_path).convert('RGB') label = torch.tensor( [row.calories,
row.protein, row.fat, row.carbs], dtype=torch.float32 ) if self.transform: img
= self.transform(img) return img, label
```

Le dataset est divisé en trois sous-ensembles : 70 % entraînement (~3 500 assiettes), 15 % validation (~750 assiettes), 15 % test (~750 assiettes). La division est effectuée par dish_id pour éviter toute fuite de données entre vues multiples de la même assiette.

4.5.2 Augmentation des données

Pour améliorer la généralisation du modèle, nous appliquons les transformations suivantes lors de l'entraînement :

Listing 4.3 – Transformations d'entraînement.

```
from torchvision import transforms train_transform = transforms.Compose([
transforms.Resize((256, 256)), transforms.RandomCrop(224),
transforms.RandomHorizontalFlip(p=0.5), transforms.ColorJitter(
brightness=0.3, contrast=0.3, saturation=0.3 ),
transforms.RandomRotation(degrees=15), transforms.ToTensor(),
transforms.Normalize( mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225] )
]) val_transform = transforms.Compose([ transforms.Resize((224, 224)),
transforms.ToTensor(), transforms.Normalize( mean=[0.485, 0.456, 0.406],
std=[0.229, 0.224, 0.225] ) ])
```

À l'évaluation, seuls le redimensionnement et la normalisation sont appliqués, sans augmentation aléatoire, afin de garantir la reproductibilité des métriques.

Conclusion

Ce quatrième chapitre a décrit l'ensemble de la stack technique : le dataset Nutrition5K (ses annotations continues et sa structure de fichiers), le pipeline end-to-end en quatre étapes, les deux backbones CNN avec leurs compromis précision/efficacité, la fonction de perte MSE multi-tâches pondérée, et le DataLoader PyTorch avec son mécanisme d'augmentation de données. Le Chapitre 5 présente la réalisation concrète et les résultats expérimentaux obtenus.

Chapitre 5
Réalisation

Introduction

Ce chapitre présente la mise en œuvre concrète du système décrit dans les chapitres précédents. Nous détaillons successivement l'environnement de développement et la configuration matérielle, la stratégie d'entraînement en deux phases, les résultats expérimentaux quantitatifs, les captures d'écran de l'application mobile, et enfin les principaux défis rencontrés au cours du projet.

5.1 Environnement de développement

5.1.1 Configuration de l'entraînement

L'entraînement du modèle a été réalisé sur Google Colab Pro, offrant l'accès à des GPU NVIDIA Tesla T4 (16 Go de VRAM) nécessaires pour les opérations de convolution sur des batchs de 32 images. Le Tableau 5.1 récapitule la configuration complète :

Composant	Spécification
GPU	NVIDIA Tesla T4 — 16 Go VRAM (Google Colab Pro)
Framework principal	PyTorch 2.1 / torchvision 0.16
Python	3.10
Librairies principales	pandas 2.0, numpy 1.24, Pillow 10.0, matplotlib 3.7, scikit-learn 1.3
API LLM	Anthropic Claude Sonnet (REST) — température 0.3
Batch size	32 (ResNet-50) / 24 (EfficientNet-B3, résolution 300×300)
Optimiseur	AdamW — lr = 1×10■■, weight_decay = 1×10■■
Scheduler	CosineAnnealingLR — T_max = 30 epochs
Durée entraînement totale	~4 h 30 min (phase 1 + phase 2, EfficientNet-B3)

Table 5.1 – Configuration de l'environnement d'entraînement.

5.2 Entraînement du modèle

5.2.1 Boucle d'entraînement

La boucle d'entraînement suit le schéma standard PyTorch. Le meilleur modèle est sauvegardé selon la MAE calories sur le jeu de validation :

Listing 5.1 – Boucle d'entraînement principale.

```
for epoch in range(num_epochs): model.train() running_loss = 0.0 for images,
labels in train_loader: images, labels = images.to(device), labels.to(device)
optimizer.zero_grad() preds = model(images) # shape: (B, 4) loss =
criterion(preds, labels) loss.backward() optimizer.step() running_loss +=
loss.item() # Validation val_mae = evaluate(model, val_loader, device)
scheduler.step() if val_mae < best_mae: best_mae = val_mae
torch.save(model.state_dict(), 'best_model.pth') print(f'Epoch {epoch+1} |
```

```
Loss: {running_loss:.4f} | Val MAE: {val_mae:.2f}')
```

5.2.2 Stratégie de fine-tuning

Nous adoptons une stratégie de fine-tuning en deux phases pour stabiliser l'apprentissage :

— **Phase 1 — Head-only (epochs 1–30) :** le backbone CNN est gelé (requires_grad = False sur tous ses paramètres). Seule la tête de régression MLP est entraînée avec lr = 1×10■³. Cette phase permet à la tête de converger vers des prédictions cohérentes sans déstabiliser les représentations pré-entraînées sur ImageNet.

— **Phase 2 — Full fine-tuning (epochs 31–40) :** tous les paramètres du modèle sont dégelés. Le learning rate est réduit à lr = 1×10■■ (10× inférieur à la phase 1) et le scheduler CosineAnnealingLR redémarre avec T_max = 10. Cette phase permet au backbone d'adapter ses représentations aux spécificités visuelles du dataset Nutrition5K (éclairage homogène, vue de dessus) tout en préservant les features générales apprises sur ImageNet.

5.3 Résultats expérimentaux

5.3.1 Métriques obtenues

Le Tableau 5.2 présente les métriques MAE et RMSE obtenues sur le jeu de test pour les deux architectures, comparées à la baseline rapportée dans le papier Nutrition5K original :

Modèle	MAE Cal. (kcal)	MAE Prot. (g)	MAE Lip. (g)	MAE Glu. (g)	RMSE Cal.
ResNet-50 (phase 1 seule)	58.3	7.8	6.1	9.4	81.2
ResNet-50 (full fine-tuning)	42.1	5.9	4.7	7.2	61.4
EfficientNet-B3 (full fine-tuning)	36.4	5.1	4.1	6.3	53.7
Baseline papier Nutrition5K [3]	44.0	5.8	5.2	7.1	63.2

Table 5.2 – Résultats expérimentaux (MAE et RMSE sur le jeu de test). La ligne en vert correspond au meilleur modèle obtenu.

Notre meilleur modèle (EfficientNet-B3 avec full fine-tuning) obtient une MAE calories de 36.4 kcal, soit une amélioration de 17.3 % par rapport à la baseline du papier original (44.0 kcal). Les gains sont cohérents sur l'ensemble des macronutriments, avec des MAE de 5.1 g (protéines), 4.1 g (lipides) et 6.3 g (glucides).

5.3.2 Courbes d'entraînement

Les courbes de loss d'entraînement et de validation présentent un comportement caractéristique en deux temps. Durant la Phase 1 (epochs 1–30), la loss de validation décroît rapidement durant les 8 premières epochs (de ~0.45 à ~0.20) puis se stabilise autour de 0.18, sans signe d'overfitting notable — ce qui confirme l'efficacité du Dropout 0.3 dans la tête de régression.

Au démarrage du full fine-tuning (epoch 31), une légère augmentation transitoire de la loss de validation est observée (+0.02 à +0.04), phénomène attendu lors du dégel du backbone. La loss reprend ensuite sa décroissance pour atteindre ~0.14 en fin d'entraînement. L'écart train/validation

reste inférieur à 0.02 sur l'ensemble des 40 epochs, indiquant une bonne généralisation du modèle.

5.3.3 Analyse des erreurs

L'analyse qualitative des prédictions sur le jeu de test révèle trois catégories d'erreurs principales :

— **Plats composites :** les assiettes contenant plusieurs aliments distincts (salades composées, plateaux avec accompagnements multiples) génèrent les erreurs les plus importantes (MAE > 70 kcal). Le modèle tend à sous-estimer les portions des aliments secondaires.

— **Aliments à forte densité calorique :** pour les aliments comme les fromages, noix ou sauces à base d'huile, une légère variation de portion entraîne un écart important sur les lipides prédit. La vue de dessus ne permet pas d'estimer précisément l'épaisseur ou le volume de ces aliments.

— **Aliments similaires visuellement mais nutritionnellement différents :** les viandes blanches grillées et frites partagent des apparences similaires mais présentent des profils lipidiques très différents, ce qui induit des erreurs systématiques sur les lipides pour cette catégorie.

5.4 Captures d'écran de l'application

L'interface utilisateur a été développée en Flutter pour assurer la compatibilité Android/iOS avec une base de code unique. L'application se compose de trois écrans principaux :

— **Écran de capture :** accès à la caméra native avec un cadre de composition centré, un bouton de capture et une option d'import depuis la galerie. Un indicateur visuel signale quand l'image est bien cadrée pour une reconnaissance optimale.

— **Écran de résultats :** affichage des quatre macronutriments sous forme de cards colorées (calories en orange, protéines en bleu, lipides en jaune, glucides en vert), accompagnées d'un graphique en anneau montrant la répartition énergétique du repas. Le temps d'inférence CNN (~12 ms) est imperceptible pour l'utilisateur.

— **Écran de coaching :** présentation du conseil nutritionnel généré par le LLM, avec mise en forme Markdown et possibilité de sauvegarder le conseil dans l'historique de l'utilisateur. Le délai de génération du conseil LLM est de 1.5–3.5 secondes selon la connexion réseau.

5.5 Défis rencontrés

— **Accès et téléchargement du dataset Nutrition5K :** la procédure d'accès via Google Research a nécessité plusieurs semaines de validation. Nous avons travaillé sur un sous-ensemble de 1 000 assiettes pendant cette période avant d'obtenir l'accès complet au dataset de 5 006 assiettes.

— **Déséquilibre des échelles entre macronutriments :** les calories ont une magnitude 10 à 20 fois supérieure aux autres macronutriments, ce qui déséquilibre la MSE brute. La détermination du coefficient w_cal optimal (0.05) a nécessité plusieurs itérations d'expérimentation.

— **Pivot architectural au sprint 4 :** l'abandon de l'approche FAISS au profit de la régression directe a impliqué une refonte partielle du pipeline de données et de la tête de modèle. Cette décision, bien que coûteuse en temps (~2 semaines), s'est avérée décisive pour les performances finales.

— **Gestion de la mémoire GPU :** EfficientNet-B3 avec une résolution de 300×300 pixels et batch size 32 dépassait la VRAM disponible (16 Go). Nous avons réduit le batch size à 24 et utilisé le gradient checkpointing pour réduire l'empreinte mémoire sans compromettre la convergence.

— **Coût et latence de l'API LLM :** lors des tests intensifs, les coûts de l'API LLM se sont révélés significatifs à grande échelle. Nous avons implémenté un système de cache basé sur un hachage des valeurs nutritionnelles prédites (arrondie au gramme/kilocalorie) pour réduire le nombre d'appels effectifs de 60 % lors des sessions de test répétées.

Conclusion

Ce cinquième chapitre a présenté la réalisation concrète du système. Les résultats expérimentaux démontrent la supériorité d'EfficientNet-B3 avec full fine-tuning (MAE calories = 36.4 kcal), surpassant la baseline du papier Nutrition5K. L'application Flutter offre une expérience utilisateur fluide, du snap de l'assiette au conseil nutritionnel personnalisé en moins de 4 secondes. La conclusion générale synthétise ces résultats et propose des axes d'amélioration.

Conclusion générale et perspectives

Bilan du projet

Ce Projet de Fin d'Année a permis de concevoir, implémenter et évaluer un système complet d'estimation nutritionnelle à partir d'images alimentaires. Trois contributions principales se dégagent de ce travail.

Premièrement, nous avons démontré la **viabilité de la régression CNN multi-tâches directe** comme alternative aux approches classiques classification + base de données. Notre meilleur modèle (EfficientNet-B3, full fine-tuning) obtient une MAE calories de 36.4 kcal sur le jeu de test de Nutrition5K, soit une amélioration de 17.3 % par rapport à la baseline publiée dans le papier original. Cette performance est atteinte sans aucune base de données externe lors de l'inférence.

Deuxièmement, nous avons validé la **faisabilité d'une architecture déployable sur mobile** : le modèle EfficientNet-B3 tient en un fichier de poids de ~50 Mo, s'exécute en ~16 ms par image sur GPU, et peut être quantifié pour un déploiement on-device sans recours à un serveur externe. Cette légèreté architecturale différencie fondamentalement notre approche des systèmes basés sur FAISS ou des classifieurs couplés à des bases de données massives.

Troisièmement, l'**intégration du module LLM** de coaching nutritionnel a démontré sa valeur ajoutée en termes d'expérience utilisateur. Le système de mitigation des hallucinations (ancrage sur les données CNN, température faible, validation de sortie) garantit que les conseils générés restent cohérents avec les prédictions numériques, évitant les dérives factuelles qui représentent le risque principal des LLMs dans les applications de santé.

Défis et limitations

Plusieurs limitations importantes doivent être mentionnées pour contextualiser ces résultats.

Estimation des portions. L'absence d'information de profondeur (nous utilisons uniquement le canal RGB) constitue la limitation principale. Le modèle encode implicitement la taille des portions dans les caractéristiques visuelles, ce qui produit des erreurs importantes pour les aliments dont la taille varie fortement sans signature visuelle distinctive (fromages tranchés, sauces).

Couverture géographique du dataset. Nutrition5K est dominé par les cuisines nord-américaines. Les performances sur des plats marocains, méditerranéens ou asiatiques non représentés dans le dataset d'entraînement sont inférieures, ce qui représente un enjeu important pour un déploiement dans le contexte EMSI et le marché marocain.

Validation clinique. Le système est un prototype académique non validé selon les standards médicaux. Une utilisation dans un contexte clinique (accompagnement de patients diabétiques, prescription diététique) nécessiterait une validation rigoureuse sur des populations cibles et une certification réglementaire appropriée.

Perspectives d'amélioration

Plusieurs axes d'amélioration sont envisagés pour les versions futures du système :

— **Intégration de la profondeur (RGB-D) :** les cartes de profondeur déjà présentes dans Nutrition5K (caméra RealSense D435) n'ont pas été exploitées dans ce projet. Un modèle bimodal fusionnant les features RGB et profondeur permettrait d'améliorer significativement l'estimation des portions, en particulier pour les aliments à forte densité calorique.

— **Collecte de données locales :** la constitution d'un sous-dataset de plats marocains et méditerranéens annotés permettrait d'adapter le modèle au contexte culturel local et d'améliorer les performances sur les cuisines sous-représentées dans Nutrition5K.

— **LLM on-device :** le déploiement d'un LLM léger (Phi-3-mini, Gemma 2B ou LLaMA 3.2 1B) directement sur l'appareil permettrait d'éliminer la dépendance réseau pour la génération de conseils, garantissant un fonctionnement entièrement hors-ligne et supprimant le coût des APIs LLM tierces.

— **Segmentation alimentaire fine :** l'intégration de Segment Anything Model (SAM) [8] en amont du pipeline permettrait d'isoler chaque aliment individuel dans une assiette composite avant d'appliquer la régression séparément, améliorant la précision sur les plats mixtes qui représentent actuellement la principale source d'erreurs.

— **Apprentissage continu (continual learning) :** la mise en place d'un mécanisme de feedback utilisateur (correction des prédictions via l'interface) permettrait d'améliorer le modèle en production sans nécessiter de réentraînement complet, grâce à des techniques d'apprentissage continu qui évitent le catastrophic forgetting.

En définitive, ce projet démontre qu'une approche de régression visuelle directe — sans base de données, sans classification intermédiaire — constitue une alternative solide, déployable et extensible aux approches classiques de reconnaissance alimentaire. La convergence entre vision par ordinateur et grands modèles de langage ouvre des perspectives passionnantes pour le développement de systèmes de suivi nutritionnel de nouvelle génération, véritablement utiles à la santé publique.

Bibliographie

[1] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," in *Proc. IEEE CVPR*, 2016, pp. 770–778.

[2] M. Tan and Q. Le, "EfficientNet : Rethinking Model Scaling for Convolutional Neural Networks," in *Proc. ICML*, 2019, pp. 6105–6114.

[3] Q. Thames, A. Karpur, W. Norris, F. Xia, L. Panait, T. Pointing, and G. Sherwood, "Nutrition5K : Towards Automatic Nutritional Understanding of Generic Food," in *Proc. IEEE CVPR*, 2021, pp. 8244–8253.

[4] L. Bossard, M. Guillaumin, and L. Van Gool, "Food-101 — Mining Discriminative Components with Random Forests," in *Proc. ECCV*, 2014, pp. 446–461.

[5] Y. Kawano and K. Yanai, "Automatic Expansion of a Food Image Dataset Leveraging Existing Categories with Domain Adaptation," in *Proc. ECCV Workshop TASK-CV*, 2014.

[6] A. Meyers et al., "Im2Calories : Towards an Automated Mobile Vision Food Diary," in *Proc. IEEE ICCV*, 2015, pp. 1233–1241.

[7] J. Johnson, M. Douze, and H. Jégou, "Billion-Scale Similarity Search with GPUs," *IEEE Trans. Big Data*, vol. 7, no. 3, pp. 535–547, 2019.

[8] A. Kirillov et al., "Segment Anything," in *Proc. IEEE ICCV*, 2023.

[9] P. Khosla et al., "Supervised Contrastive Learning," in *Advances in NeurIPS*, 2020.

[10] A. Radford et al., "Learning Transferable Visual Models From Natural Language Supervision," in *Proc. ICML*, 2021, pp. 8748–8763.